

UPC
Universidad Peruana
de Ciencias Aplicadas

UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

Facultad de Ingeniería

Carrera de Ciencias de la Computación

MODELO FLY

Recomendación de outfits a partir del conectoma del Giant Fiber System

Informe del Trabajo Parcial · Hitos 1, 2 y 3

CRISP-DM: Fases 1 a 5 · Refinamiento, modelado avanzado e integración

Alineado con el ODS 12: Producción y consumo responsables

Curso: Machine Learning (1ACC0057)

NRC: _____

Grupo 5

Integrantes:

Nicole Sihuincha Schermuly

Sergio Sebastián Iglesias Pérez

Profesor: Hector Erasmo Gomez Montoya

Lima, noviembre de 2026

ÍNDICE

I. Resumen ejecutivo 4
Cambios respecto al Hito 2 4
II. Marco metodológico: CRISP-DM aplicado 5
1. Business Understanding 5
1.1. Problema y objetivo de ML 5
1.2. Variables objetivo 5
1.3. Hipótesis 5
1.4. Criterios de éxito técnico 6
2. Data Understanding y EDA 6
2.1. Fuentes de datos 6
2.2. Polyvore 6
2.3. Catálogo propio: calidad 7
2.4. Validación manual de los atributos de Polyvore 7
2.5. Conectoma del Giant Fiber System 7
3. Data Preparation y Feature Engineering 8
3.1. Embudo de datos de Polyvore 8
3.2. Atributos y color desde la foto 8
3.3. Partición sin fuga de productos 8
3.4. Negativos y reglas de armonía 8
3.5. Usuarios simulados 9
3.6. Codificación de la entrada 10
3.7. Candidatos para el ranking 10
4. Modeling 10
4.0. Punto de partida: el baseline del Hito 2 10
4.1. Fase 2: árboles con ajuste de hiperparámetros y validación cruzada 10
4.2. Fase 2: red con la conectividad del Giant Fiber System 11
4.3. Fase 1: DeepFM 11
4.4. Combinación de las dos fases 11
4.5. Modelo seleccionado 12
5. Evaluation 12
5.1. Fase 2 en test: ¿el outfit combina? 12
5.2. Análisis de errores de la fase 2 13
5.3. Interpretabilidad 14
5.4. Fase 1: DeepFM 14
5.5. Ranking final: los seis experimentos 15
5.6. Contraste de H1 16

5.7. Análisis de errores del ranking 16
III. Implementación e integración con la base de datos común 18
1. Arquitectura 18
2. Evidencia de integración 18
3. Dashboard 19
IV. Análisis de impacto ODS y ética de datos 20
1. Impacto en el ODS 12 20
2. Sesgos y ética 20
V. Confluencia con el ecosistema y lecciones aprendidas 21
1. Cómo consume el modelo los datos de la BD común 21
2. Lecciones aprendidas 21
VI. Conclusiones y siguientes pasos 21
Limitaciones 21
Bibliografía 23
Anexos 24
A. Repositorio y reproducibilidad 24
B. Diccionario de datos 24

I. Resumen ejecutivo

Problema. Las personas usan una fracción pequeña de la ropa que tienen y compran prendas nuevas para tener algo distinto que ponerse. Modelo Fly recomienda outfits armados **solo con las prendas que el usuario ya tiene**, de acuerdo con su gusto, para que la ropa del clóset se use más (ODS 12, producción y consumo responsables).

Pregunta de investigación. ¿Sirve la conectividad real de un circuito de decisión de la mosca *Drosophila melanogaster*, el Giant Fiber System (MaleCNS v1.0, 327 neuronas), como arquitectura de una red neuronal para decidir si un outfit combina? Se contrasta con controles justos: un MLP con el mismo número de parámetros, la misma red con las conexiones barajadas, XGBoost y Random Forest.

Qué se hizo en el Hito 3. Se rehízo el dataset desde cero, porque el del Hito 2 tenía fuga entre particiones y etiquetas circulares. Las fuentes son 15 012 outfits reales de Polyvore (Han et al., 2017), con atributos sacados del texto y de la foto y validados a mano; el catálogo propio de 500 prendas; el subgrafo del conectoma con el signo de cada conexión; y 350 usuarios simulados con clóset e historial. El sistema tiene dos fases:

- **Fase 1, DeepFM:** aprende el gusto de cada usuario y filtra el 25 % de los outfits de su clóset que más le gustarían.
- **Fase 2, ¿el outfit combina?:** reordena ese top con dos salidas inspiradas en la mosca: TTMn (outfit real o falso) y DLMn (armonía de 0 a 7 según siete reglas).

Resultados principales (test, 350 usuarios, 100 candidatos cada uno):

- El DeepFM ordena los candidatos con NDCG@5 = **0,750** (azar 0,492; máximo alcanzable 0,919).
- El mejor sistema es **DeepFM + Random Forest**, con NDCG@5 = **0,767**. Es el que se integró con la base de datos común.
- La red con la conectividad de la mosca obtiene 0,744: **empata** con el MLP de igual tamaño (p = 0,98) y **no se distingue** de su versión barajada (p = 0,48). Los datos no apoyan que la conectividad específica del Giant Fiber System aporte (se acepta H0 para esa parte de la hipótesis).
- **Integración:** la función recomendar(user_id) lee el clóset y el historial desde el libro Excel que hace de base de datos común, recomienda tres outfits sin prendas repetidas y escribe el resultado en el mismo libro.
- **Impacto ODS 12:** el usuario aceptaría el **80,3 %** de las recomendaciones, frente al 52,4 % si eligiera outfits al azar de su clóset (+53 %).

Cambios respecto al Hito 2

Tabla 1. Qué cambió y por qué.

Hito 2	Hito 3	Motivo
100 000 outfits sintéticos etiquetados con reglas	15 012 outfits reales de Polyvore + 30 024 negativos	Fuga entre particiones y outfits de 3 prendas siempre compatibles: el baseline llegaba a ~0,99 sin aprender nada útil

Hito 2	Hito 3	Motivo
Una etiqueta (compatible sí/no) y un score pegado a ella	TTMn (real/falso) y DLMn (reglas 0–7) por separado, más el gusto del usuario	El score y la etiqueta salían de la misma regla (r = 0,955)
Clasificador de outfits	Recomendador en dos fases sobre el clóset de cada usuario	Observación del profesor: personalizar según clóset e historial
Conectoma sin signo; «20 684 sinapsis»	Signo por neurotransmisor; 20 684 **conexiones** y 79 950 sinapsis	Corrección de la cifra del Hito 2 y Opción A del modelo
Partición al azar	Partición sin productos compartidos entre train, valid y test	Al azar, el 70 % de los outfits de test tendría un producto visto en train

II. Marco metodológico: CRISP-DM aplicado

El trabajo sigue las seis fases de CRISP-DM (Chapman et al., 2000). Este informe reúne lo entregado hasta el Hito 3: comprensión del negocio y de los datos (Hito 1), preparación y baseline (Hito 2), y modelado avanzado, evaluación robusta e integración con la base de datos común (Hito 3). Las fases 1 a 3 se presentan en su versión actualizada, porque en el Hito 3 el dataset se reconstruyó. Cada etapa del código se entregó como una rama y un pull request en el repositorio (13 en total), a modo de incremento de SCRUM.

1. Business Understanding

1.1. Problema y objetivo de ML

Objetivo de negocio: que una persona encuentre en su propio clóset un outfit que le guste y que combine, en lugar de comprar ropa nueva.

Objetivo de ML: para cada usuario, ordenar los outfits posibles de su clóset de modo que los primeros sean los que aceptaría. Se mide con NDCG@K, Recall@K y HitRate@K por usuario contra lo que aceptó en el periodo de test.

1.2. Variables objetivo

Tabla 2. Variables objetivo del sistema.

Variable	Qué predice	Tipo	Modelo
aceptado	Si al usuario le gusta el outfit (1/0)	Binaria, por usuario	DeepFM (fase 1)
real (TTMn)	Si el outfit lo armó una persona en Polyvore o es un negativo	Binaria	Fase 2
score_reglas (DLMn)	Cuántas de las 7 reglas de armonía no viola el outfit	Entera 0–7 (regresión)	Fase 2

Las dos salidas de la fase 2 llevan el nombre de las motoneuronas de la mosca donde se leen en la red GFS: **TTMn** (músculo del salto) y **DLMn** (músculo del vuelo).

1.3. Hipótesis

- **H1:** en el ranking final, DeepFM + red GFS (Opción A) obtiene un NDCG@5 igual o mayor que los controles de igual tamaño (MLP) y de conectividad aleatoria (GFS barajada).

- **H0:** no hay diferencia, o la red GFS es peor.

1.4. Criterios de éxito técnico

Los criterios del Hito 2 (accuracy ≥ 0,82, F1 ≥ 0,85) no discriminaban: un modelo trivial los cumplía. Se reemplazaron por criterios relativos a referencias medidas en los mismos datos:

Tabla 3. Criterios de éxito.

Criterio	Umbral	Resultado
El ranking supera al azar	NDCG@5 > 0,492	Se cumple: 0,767 (mejor sistema)
La fase 2 distingue real de falso	AUC TTMn > 0,5 y mejor que el score de reglas (0,539)	Se cumple: 0,640 (XGBoost), 0,623 (RF)
DLMn mejora a predecir siempre 7	MAE < 0,307	Se cumple con árboles (0,179); no con las redes GFS
Prueba de H1	Wilcoxon pareado por usuario, IC 95 % por bootstrap, corrección de Holm	Realizada: H1 no se sostiene frente a la red barajada
Integración	recomendar() lee y escribe la BD común	Se cumple: +600 filas en candidatos y +9 en predicciones

2. Data Understanding y EDA

2.1. Fuentes de datos

Tabla 4. Fuentes de datos del Hito 3.

Fuente	Contenido	Rol
Polyvore (Han et al., 2017), licencia Apache 2.0	21 889 outfits armados por personas; 142 480 ítems (111 589 productos distintos)	Verdad de compatibilidad: entrena la fase 2
Re-PolyVore en Kaggle (copia de las fotos)	126 928 fotos de productos	Color dominante de cada prenda
Catálogo propio (Hito 1–2)	500 prendas con color, patrón, estilo, época, talla	Prendas para los clósets (sin etiquetas de compatibilidad)
neuPrint, MaleCNS v1.0 (Berg et al., 2026)	327 neuronas, 20 684 conexiones, 79 950 sinapsis químicas	Arquitectura de la red GFS
Usuarios simulados (este trabajo)	350 usuarios, 20 997 prendas en clósets, 17 500 decisiones	Gusto personal para el DeepFM

2.2. Polyvore

Los outfits tienen de 4 a 8 ítems y la partición oficial no comparte productos. Las 380 categorías se asignaron a 8 lugares del outfit (slots): arriba, abajo, vestido, exterior, calzado, bolso, accesorio y joyería. El equipo revisó la tabla y cambió 4 categorías. Se excluyó el 22,3 % de los ítems (belleza, hogar, tecnología, ropa interior, niños y ropa de baño).

Valores faltantes. El nombre del producto en inglés es la única descripción. Sin la foto, el color se conocía solo en el 30,3 % de las prendas y apenas el 1,1 % de los outfits tenía el color de todas sus prendas, que es lo que necesitan las reglas de color. Otros atributos tienen mucho desconocido: estilo 82 %, calce 83 %, largo 73 %, material 68 %. La época casi nunca se menciona (97 % contemporáneo), por eso la regla de épocas (Ep1) no aplica en Polyvore.

2.3. Catálogo propio: calidad

El catálogo propio lo generó una IA y sus atributos parecen asignados casi al azar:

- el estilo de la columna coincide con el de la descripción en solo 66 de 500 prendas (13 %, lo mismo que el azar entre 8 valores), y se contradicen en 205;
- hay 38 camisetas de cuero, denim o terciopelo y 22 calzados con talla de ropa;
- la columna color tiene 69 valores y algunos no son colores («Vintage», «Pastel»).

El equipo revisó las 153 prendas sospechosas con una regla escrita antes de empezar y las conservó todas. Por estos problemas el catálogo **no se usa como verdad**, solo como prendas para recomendar.

2.4. Validación manual de los atributos de Polyvore

Para responder a la observación del profesor sobre datos sin verificar, una persona comparó los atributos con la foto real de 200 prendas (25 por slot, al azar con semilla fija). Como la primera revisión aceptaba implícitamente lo que no cambiaba, el color se volvió a revisar **a ciegas** (sin ver el nombre ni el origen del color) en 40 prendas. Estas son las cifras de color que se informan:

Tabla 5. Precisión de los atributos (IC 95 % de Wilson).

Atributo	Revisadas	Precisión	IC 95 %
Slot	200	100 %	98,1–100
Patrón	199	99,5 %	97,2–99,9
Estilo	30	93,3 %	78,7–98,2
Material	70	100 %	94,8–100
Tono de color (a ciegas)	40	82,5 %	68,0–91,3
Familia de color (a ciegas)	40	92,5 %	80,1–97,4

2.5. Conectoma del Giant Fiber System

Se descargó el mismo subgrafo del Hito 2 desde neuPrint (Plaza et al., 2022), esta vez con el neurotransmisor de cada neurona. Tiene 7 tipos: LC4 (126) y LPLC2 (185) en la entrada, DNp01 o Giant Fiber (2), PSI (2), TTMn (2) y DLMn (10). Hallazgos que condicionan el modelo:

- **Corrección del Hito 2:** 20 684 son conexiones (pares de neuronas), no sinapsis; el subgrafo tiene 79 950 sinapsis químicas.
- **Casi todo es excitador:** solo el 0,27 % de las conexiones es inhibidor, y todas salen de las motoneuronas. El signo restringe poco; lo que aporta la biología es **qué neurona se conecta con cuál** (máscara con densidad 19,3 %).
- **Cuello de botella:** toda la señal hacia la salida pasa por las 2 neuronas DNp01. Desde la entrada hay 2 saltos hasta TTMn y 3 hasta DLMn, como en el reflejo de escape.
- neuPrint solo cuenta sinapsis químicas: las eléctricas GF→TTMn y GF→PSI no están.

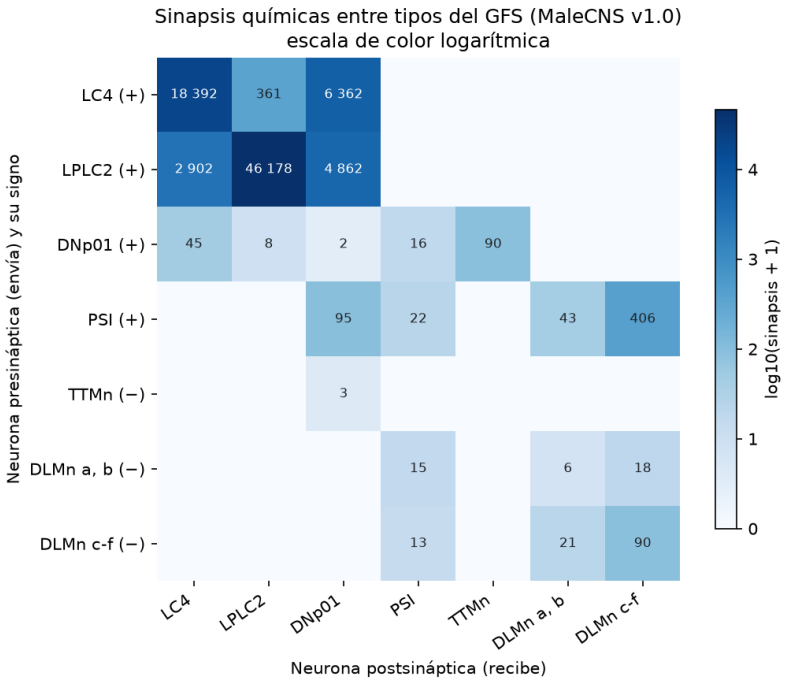


Figura 1. Sinapsis entre tipos de neurona del Giant Fiber System (fila = envía, columna = recibe) y su signo.

3. Data Preparation y Feature Engineering

3.1. Embudo de datos de Polyvore

Un outfit se considera **vestible** si tiene un vestido solo, o una prenda de abajo con una o dos de arriba, exactamente un calzado y como mucho un exterior; bolso, accesorios y joyería son libres. De 21 889 outfits quedan **15 012 (69 %)**. Los motivos principales de descarte son: sin prenda principal (3 402), sin calzado (878) y sin prendas de moda (861).

3.2. Atributos y color desde la foto

De cada nombre se sacan, con diccionarios de palabras clave, el tono, la familia de color, el patrón, el material, el estilo, el calce, la época y el largo. Cuando el nombre no dice el color, se toma el **color dominante de la foto**: se quita el fondo y cada píxel se asigna al tono más cercano en el espacio CIELAB. Siempre manda el texto; la foto solo rellena. Con esto, las prendas con color conocido pasan de **30,3 % a 82,7 %** y los outfits con el color de todas sus prendas, de **1,1 % a 40,0 %**.

3.3. Partición sin fuga de productos

Los productos se repiten mucho entre outfits: al unir los outfits que comparten productos, un solo grupo junta el 70,8 %. Con una partición al azar, el 70 % de los outfits de valid y test tendría algún producto ya visto en train. Para evitarlo se mueven **grupos completos** de outfits. Resultado: train 10 625 (70,8 %), valid 2 194 (14,6 %) y test 2 193 (14,6 %), con **0 productos** en dos particiones.

3.4. Negativos y reglas de armonía

Por cada outfit real se arman dos negativos con prendas del mismo slot y de la misma partición: **aleatorio** (se cambian todas las prendas, como en Han et al., 2017) y **difícil** (se cambia una sola). Así se obtienen 45 036 outfits, un tercio reales. Las siete reglas se evalúan sobre los atributos; una regla que no aplica cuenta como cumplida.

Tabla 6. Reglas de armonía (etiqueta DLMn).

Regla	Cómo se mide	Fuente
C1	Como máximo 2 tonos no neutros y 1 tono fuerte	Dior (1954); Itten (1961)
C2	Con ≥ 2 tonos no neutros, al menos una prenda neutra	Itten (1961); Flusser (2002)
P1	Dos estampados distintos deben compartir un tono (aproximación)	Flusser (2002)
P2	No repetir el mismo tipo de estampado (aproximación)	Flusser (2002)
P3	Con ≥ 2 prendas estampadas, al menos una lisa	Flusser (2002)
E1	Como máximo una prenda oversize	Faerm (2010)
Ep1	No todas las prendas de la misma década	García (2007)

El 80,8 % de los outfits reales cumple 7/7: la etiqueta DLMn está muy desbalanceada, así que se compara con un modelo que siempre predice 7. Las reglas separan poco lo real de lo falso (AUC 0,539). **Hallazgo:** la regla P2 se cumple al revés: las personas repiten el mismo estampado **más** que el azar (3,4 % frente a 2,3 %), por ejemplo en conjuntos de dos piezas.

3.5. Usuarios simulados

Polyvore no trae usuarios, así que se simularon **350**: 300 con clóset mixto (70 % Polyvore y 30 % catálogo propio) y 50 de **transferencia** (clóset 100 % del catálogo propio), para probar el cambio de dominio. Cada uno tiene arquetipo, estilo favorito, edad, género, ciudad del Perú y su clima, y un clóset de 40 a 80 prendas. Las prendas Polyvore de los clósets salen solo de valid y test: la fase 2 nunca las ve al entrenar. Cada usuario ve 50 outfits en orden de fecha y decide según:

$$\text{utilidad} = -\Sigma\, w_k \cdot \text{viola}_k + b \cdot \text{estilo} + c \cdot \text{clima} + d \cdot \text{neutros} + e \cdot \text{compatibilidad humana}$$

$$p(\text{acepta}) = \text{sigmoide}(1{,}5 \cdot (\text{utilidad} - \text{sesgo})), \quad \text{con } 5\text{–}10\ \% \text{ de decisiones invertidas (ruido)}$$

La **compatibilidad humana** se aprendió de Polyvore: compara qué tan seguido aparecen juntos los atributos de cada par de prendas en outfits reales frente a aleatorios, contado solo en train. Se agregó para que la etiqueta no saliera solo de las reglas, lo que habría vuelto el problema circular. Separa lo real de lo falso mucho mejor que las reglas (AUC 0,702 frente a 0,535). La aceptación global es del 49,0 %. El historial se parte por tiempo en **35 / 7 / 8** decisiones por usuario, y ningún outfit de test de un usuario aparece en el train de otro.

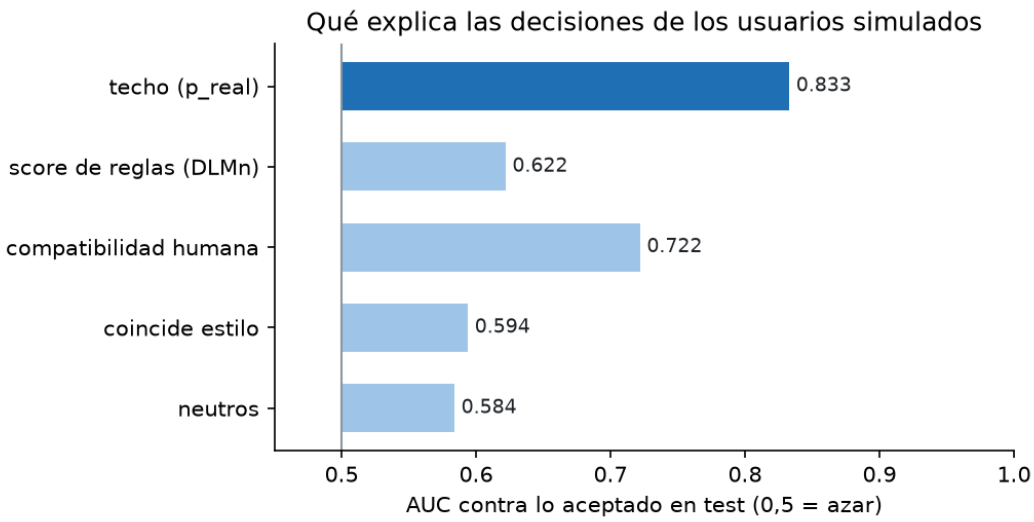


Figura 2. Qué tan bien explica cada señal las decisiones de test (AUC). El techo es la probabilidad real de la simulación: el ruido no se puede predecir.

3.6. Codificación de la entrada

Cada outfit se codifica como una bolsa de prendas: por cada slot, cuántas prendas tiene y cuántas tienen cada valor de cada atributo (**464 columnas**). Todos los modelos de la fase 2 y el DeepFM ven el mismo vector. El usuario entra al DeepFM con 6 campos de registro (ID, tramo de edad, género, ciudad, clima y estilo favorito); el arquetipo y los pesos del gusto quedan **ocultos**.

3.7. Candidatos para el ranking

Cada usuario tiene una lista de outfits de su clóset para ordenar: **50 en valid** (para ajustar la combinación de fases) y **100 en test** (para reportar). La lista incluye sus decisiones reales del periodo más outfits nuevos etiquetados con su mismo gusto y ruido. En total son 52 500 candidatos, ninguno en el train de algún usuario. Todos los modelos ordenan exactamente los mismos outfits.

4. Modeling

4.0. Punto de partida: el baseline del Hito 2

En el Hito 2 se entrenaron una regresión logística y un árbol de decisión sobre los 100 000 outfits sintéticos, con métricas cercanas a 0,99. La revisión del Hito 3 mostró que esas cifras estaban infladas por tres motivos. Primero, había combinaciones repetidas entre train y test. Segundo, ningún outfit de tres prendas era incompatible, así que el número de prendas bastaba para acertar. Tercero, la etiqueta y el score salían de la misma regla. Las métricas se conservan como referencia, pero no son una línea base válida. La línea base del Hito 3 es la regresión logística sobre el dataset nuevo (sección 4.3), junto con el azar y el techo de la simulación.

4.1. Fase 2: árboles con ajuste de hiperparámetros y validación cruzada

XGBoost (Chen y Guestrin, 2016) y Random Forest (Breiman, 2001) se ajustaron con búsqueda aleatoria y **validación cruzada de 5 folds dentro de train**. Se agrupó por outfit de origen (StratifiedGroupKFold): un outfit real y sus negativos van siempre al mismo fold, para que no haya fuga entre folds. TTMn se optimizó por AUC y DLMn por MAE.

Tabla 7. Hiperparámetros elegidos y resultado de la validación cruzada.

Modelo	TTMn (clasificación)	DLMn (regresión)	CV (5 folds)
XGBoost	559 árboles, profundidad 6, lr 0,127, subsample 0,77, colsample 0,67	347 árboles, profundidad 8, lr 0,140	AUC 0,645 · MAE 0,174
Random Forest	200 árboles, profundidad 40, hoja ≥ 3, 20 % de variables, 50 % de muestras	Igual, hoja ≥ 1	AUC 0,634 · MAE 0,169

4.2. Fase 2: red con la conectividad del Giant Fiber System

El outfit entra por una capa lineal a las 311 neuronas de entrada (LC4 y LPLC2) y la actividad se propaga 4 pasos por la matriz del conectoma. TTMn se lee en las 2 motoneuronas del salto y DLMn en las 10 del vuelo. En la **Opción A**, cada conexión real tiene un peso aprendible con el signo de su neurotransmisor:

$$W = \text{signo} \odot \text{softplus}(\theta) \odot \text{máscara}$$

El signo sigue la convención de Shiu et al. (2024): acetilcolina +1; glutamato, GABA e histamina −1. Doce neuronas sin neurotransmisor fiable en neuPrint (PSI y DLMn) lo toman de la literatura. Controles:

- **MLP de igual tamaño:** 165 207 parámetros frente a 165 640 de la red GFS.
- **GFS barajada:** las mismas neuronas con conexiones reasignadas al azar, conservando cuántas entradas y salidas tiene cada neurona; solo el 24 % de las conexiones coincide con la real.
- **Opción B (anexo):** los pesos fijos de neuPrint, sin aprenderlos.

La tasa de aprendizaje de cada red se eligió en validación entre $\{3{\cdot}10^{-4}, 10^{-3}, 3{\cdot}10^{-3}\}$ y se entrenaron 3 semillas con parada temprana. La pérdida es BCE (TTMn) + MSE (DLMn).

Lección aprendida. En la primera corrida, dos de tres semillas de la red GFS quedaron en AUC ≈ 0,50. La causa fueron neuronas «muertas»: con ReLU, la señal se apagaba en las 2 neuronas DNp01, que son el único camino a TTMn. Se corrigió con leaky ReLU (pendiente 0,1) en **todas** las redes, incluido el MLP, y con el ajuste de la tasa de aprendizaje. La decisión se tomó mirando validación, no test.

4.3. Fase 1: DeepFM

El DeepFM (Guo et al., 2017) combina una parte lineal, una máquina de factorización (interacciones de a pares usuario × prenda y prenda × prenda) y una red profunda, con embeddings compartidos. Se probaron 8 configuraciones: dimensión k ∈ {8, 16}, dropout ∈ {0,1; 0,3} y regularización ∈ $\{10^{-5}; 10^{-3}\}$. Se eligió por la pérdida en el historial de valid: **k = 8, dropout 0,1 y regularización 10^{-5}**. Las 8 quedaron entre 0,660 y 0,664, así que el modelo es poco sensible a estos valores. Como línea base se usó una regresión logística con las mismas variables.

4.4. Combinación de las dos fases

El DeepFM elige el 25 % de los candidatos de cada usuario y la fase 2 reordena ese grupo con:

$$\text{score} = \alpha \cdot \text{pct}(\text{DeepFM}) + (1-\alpha) \cdot [\beta \cdot \text{pct}(\text{TTMn}) + (1-\beta) \cdot \text{pct}(\text{DLMn})]$$

Aquí pct es el rango percentil dentro del usuario. α ∈ {0; 0,1; …; 1} y β ∈ {0; 0,5; 1} se eligen en **valid** para cada experimento y semilla. α = 1 equivale al DeepFM solo, así que ningún experimento puede quedar peor que él en valid. Se usa un α común a todos los usuarios: con 50 candidatos de valid por usuario, un α propio se sobreajusta.

Tabla 8. Los seis experimentos.

Exp.	Fase 1	Fase 2	Rol
1	DeepFM	ninguna	Referencia
2	DeepFM	XGBoost	Control tabular
3	DeepFM	Random Forest	Control tabular
4	DeepFM	Red GFS (Opción A)	**Propuesta (H1)**
5	DeepFM	MLP de igual tamaño	Control de tamaño
6	DeepFM	GFS barajada	Control de conectividad

4.5. Modelo seleccionado

Se selecciona **DeepFM + Random Forest (experimento 3)**. Tiene el mejor NDCG@5 en test (0,767) y la menor variación entre semillas después de XGBoost. El Random Forest tiene además el mejor MAE de DLMn en validación cruzada (0,169). En la combinación elegida en valid ($\alpha = 0{,}6$, $\beta = 0{,}5$), la fase 2 pesa un 40 %, repartido en partes iguales entre TTMn y DLMn.

5. Evaluation

5.1. Fase 2 en test: ¿el outfit combina?

Tabla 9. Fase 2 en test (6 579 outfits; ± = desviación estándar de 3 semillas).

Exp.	Modelo	AUC TTMn	vs. aleatorio	vs. difícil	MAE DLMn
2	XGBoost	**0,640**	0,714	0,565	**0,179**
3	Random Forest	0,623	0,691	0,555	0,190
4	Red GFS (Opción A)	0,549 ± 0,039	0,576	0,523	0,341
5	MLP de igual tamaño	**0,645 ± 0,002**	0,723	0,567	0,294
6	GFS barajada	0,529 ± 0,043	0,538	0,520	0,302
Anexo	GFS Opción B (pesos fijos)	0,529 ± 0,023	0,541	0,517	0,393
—	Predecir siempre 7	—	—	—	0,307

Distinguir un outfit real de uno falso solo con atributos es difícil: el mejor modelo llega a AUC 0,64 (0,71 contra negativos aleatorios y 0,57 contra los difíciles, donde cambia una sola prenda). La red GFS queda por debajo del MLP y de los árboles. En DLMn, ninguna red GFS mejora a predecir siempre 7. La red tiene un cuello de botella: toda la información pasa por las 2 neuronas DNp01. Además es inestable: 1 de 3 semillas no aprendió.

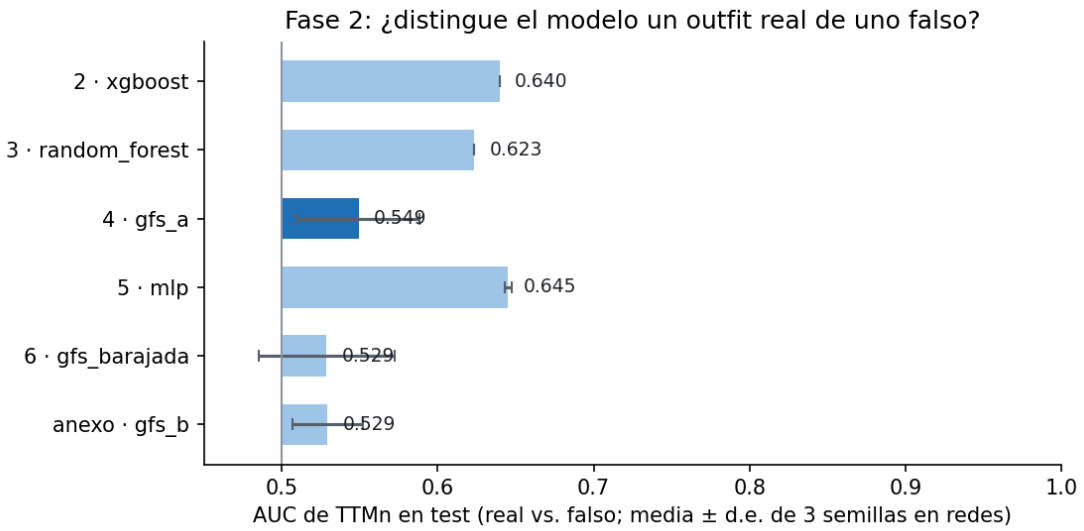


Figura 3. AUC de TTMn en test por modelo (media ± desviación estándar de 3 semillas en las redes).

5.2. Análisis de errores de la fase 2

La matriz de confusión de XGBoost usa un umbral de 0,25, elegido en validación por F1. Recupera el 76 % de los outfits reales con una precisión de 0,39 (F1 0,52, accuracy 0,527). Predecir siempre «falso» daría accuracy 0,667, porque hay dos falsos por cada real; por eso se reportan AUC y F1 y no accuracy.

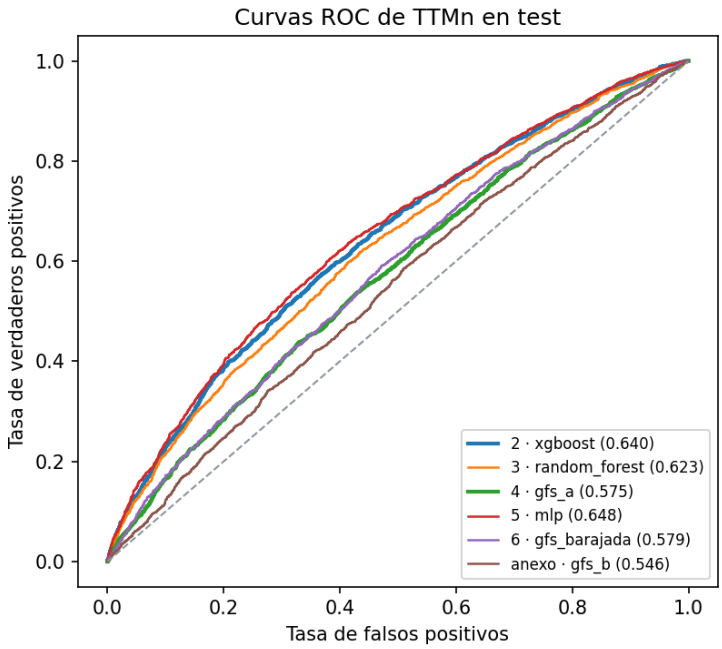


Figura 4. Curvas ROC de TTMn en test.

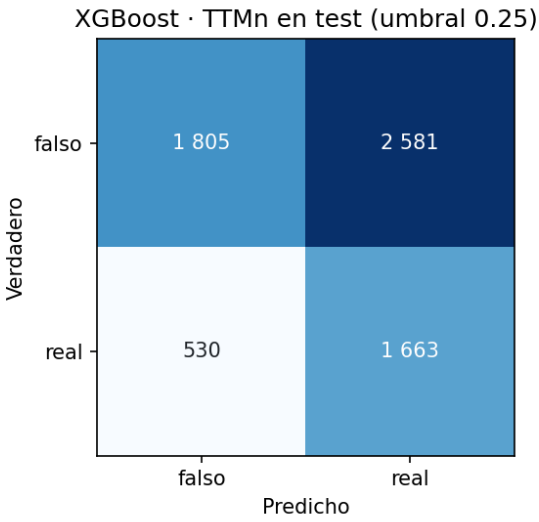


Figura 5. Matriz de confusión de XGBoost en test (umbral elegido en validación).

5.3. Interpretabilidad

Según los valores SHAP de XGBoost (Lundberg y Lee, 2017), para **TTMn** pesan prendas muy típicas de Polyvore: pantalón de denim, calzado athleisure o negro, bolso formal o negro y joyería dorada. Es decir, el modelo aprende **qué prendas suele combinar la gente**. Para **DLMn** pesan los colores fuertes en cada slot y las prendas lisas, que es justo lo que miden las reglas C1, C2 y P3: el modelo recupera las reglas.

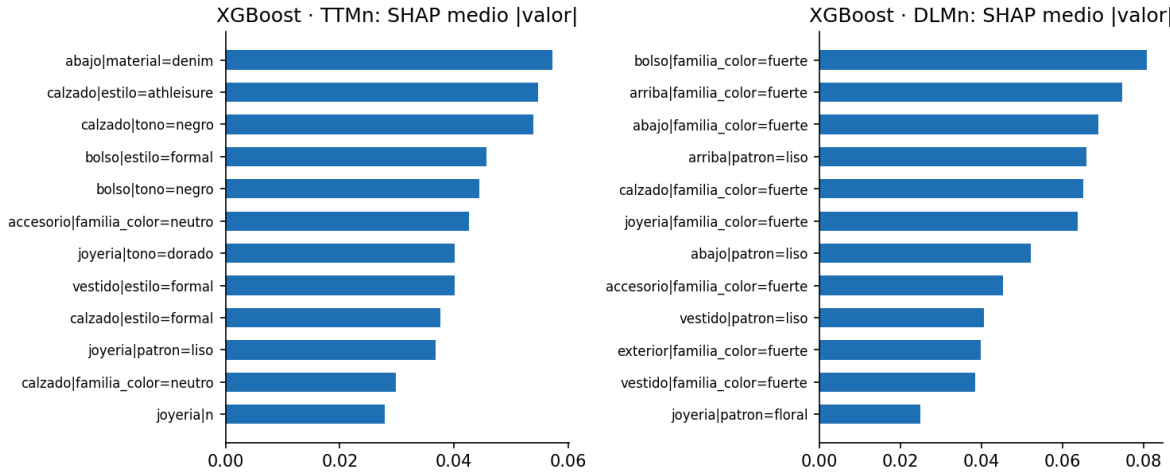


Figura 6. Variables más influyentes según SHAP (XGBoost) para TTMn y DLMn.

5.4. Fase 1: DeepFM

El DeepFM solo (experimento 1) logra NDCG@5 = **0,750 ± 0,014**, frente a 0,697 de la regresión logística con las mismas variables. La diferencia indica que las interacciones entre usuario y prenda sí aportan. Su AUC en el historial de test es 0,651–0,656. Los usuarios de transferencia (clóset 100 % del catálogo propio) obtienen 0,753, lo mismo que los mixtos (0,750): **no hay caída por cambio de dominio**.

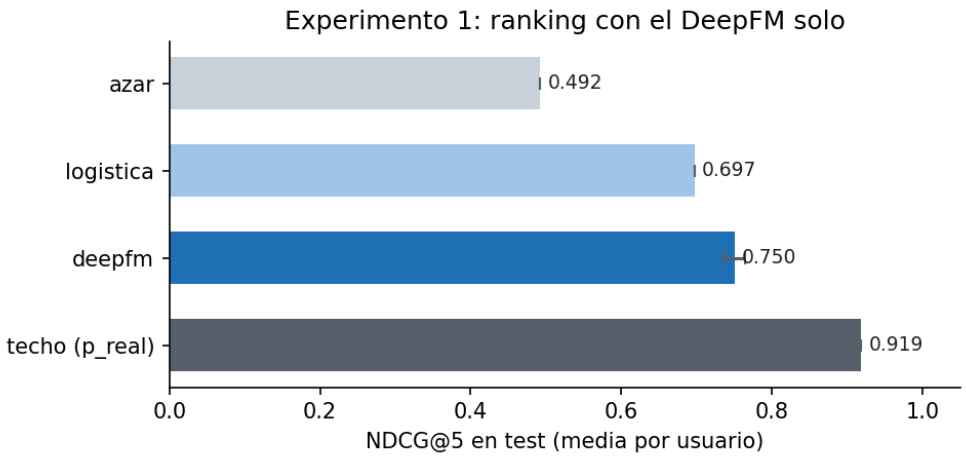


Figura 7. NDCG@5 en test del DeepFM solo frente al azar, la regresión logística y el techo.

5.5. Ranking final: los seis experimentos

Tabla 10. Ranking final en test (media por usuario; ± = desviación estándar de 3 semillas).

Exp.	Sistema	NDCG@5	NDCG@10	Recall@5	HitRate@5
—	Azar	0,492	0,493	0,496	0,971
1	DeepFM solo	0,750 ± 0,014	0,734	0,741	0,995
2	+ XGBoost	0,758 ± 0,006	0,740	0,752	0,998
3	**+ Random Forest**	**0,767 ± 0,009**	**0,742**	**0,757**	0,997
4	+ Red GFS (A)	0,744 ± 0,009	0,726	0,738	0,993
5	+ MLP igual tamaño	0,744 ± 0,015	0,731	0,739	0,995
6	+ GFS barajada	0,748 ± 0,016	0,732	0,742	0,996
Anexo	+ GFS (B, fijos)	0,751 ± 0,012	0,730	0,743	0,994
—	Techo (gusto real)	0,919	0,905	0,920	1,000

Recall@K se normaliza por min(K, aceptados), porque cerca de la mitad de los candidatos son aceptados. HitRate@5 es casi 1 en todos los sistemas, incluido el azar, por la misma razón: por eso la métrica principal es NDCG@5.

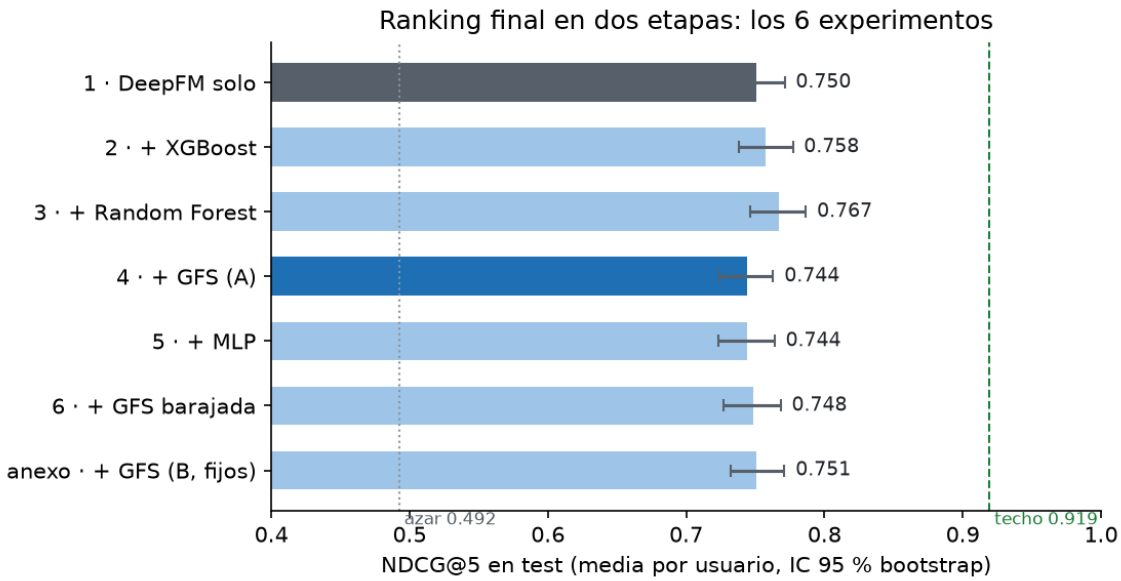


Figura 8. NDCG@5 en test de los seis experimentos, con intervalo de confianza del 95 % por bootstrap de usuarios.

5.6. Contraste de H1

Se usa la prueba de rangos con signo de Wilcoxon (1945), pareada por usuario, sobre NDCG@5 (promedio de las 3 semillas; n = 350 usuarios). El intervalo de confianza de la diferencia se obtiene por bootstrap de usuarios (5 000 remuestreos) y los valores p se corrigen por comparaciones múltiples con Holm (1979).

Tabla 11. Comparaciones pareadas de NDCG@5 en test.

Comparación	Diferencia	IC 95 %	p	p (Holm)
4 vs 5: GFS vs MLP de igual tamaño	−0,0003	[−0,013; 0,012]	0,98	1,00
4 vs 6: GFS vs GFS barajada	−0,005	[−0,014; 0,006]	0,48	1,00
4 vs 1: GFS vs DeepFM solo	−0,007	[−0,018; 0,006]	0,16	0,79
3 vs 1: Random Forest vs DeepFM solo	+0,017	[0,001; 0,033]	0,036	0,29
2 vs 1: XGBoost vs DeepFM solo	+0,007	[−0,012; 0,025]	0,58	1,00
4 vs 2: GFS vs XGBoost	−0,014	[−0,030; 0,003]	0,09	0,54

Conclusión. La red GFS **empata** con el MLP de su mismo tamaño: la primera parte de H1 se cumple en sentido de no inferioridad. Pero **no se distingue** de su versión barajada: conectar las neuronas como en la mosca real no ordena mejor que conectarlas al azar con los mismos grados. Por lo tanto, la parte central de H1, que la conectividad específica del Giant Fiber System aporte, **no se sostiene** y se acepta H0. Ninguna segunda fase mejora al DeepFM solo tras corregir por comparaciones múltiples; Random Forest suma +0,017 (p = 0,036 sin corregir).

5.7. Análisis de errores del ranking

Tabla 12. NDCG@5 en test por perfil de usuario.

Grupo	Usuarios	DeepFM solo	+ GFS	+ Random Forest
Arquetipo minimalista	76	0,835	0,820	0,820
Arquetipo clásico	80	0,789	0,787	0,815

Grupo	Usuarios	DeepFM solo	+ GFS	+ Random Forest
Arquetipo vintage	62	0,757	0,743	0,769
Arquetipo deportivo	71	0,739	0,736	0,762
Arquetipo atrevido	61	**0,601**	0,604	0,641
Clima cálido	61	0,792	0,789	0,803
Clima templado	216	0,744	0,741	0,763
Clima frío	73	0,736	0,716	0,749
Clóset mixto	300	0,750	0,741	0,765
Clóset 100 % propio (transferencia)	50	0,753	0,761	0,781

- **El arquetipo «atrevido» es el más difícil** (0,601). Le importan poco las reglas y prefiere colores fuertes, así que su gusto se parece menos al de los demás usuarios. La segunda fase ayuda justo ahí (+0,040 con Random Forest).
- **¿El DeepFM recupera el gusto programado?** La correlación de Spearman media entre su probabilidad y la probabilidad real de la simulación es **0,50**: 0,66 en minimalistas y clásicos, y solo 0,14 en los atrevidos. La salida TTMn de la fase 2, que no ve al usuario, llega a 0,25 con XGBoost y 0,19 con la GFS: capta la parte del gusto que es común a todos.
- En clima frío la red GFS empeora el ranking (0,716 frente a 0,736): el abrigo cambia la composición del outfit y la red lo maneja peor que los árboles.

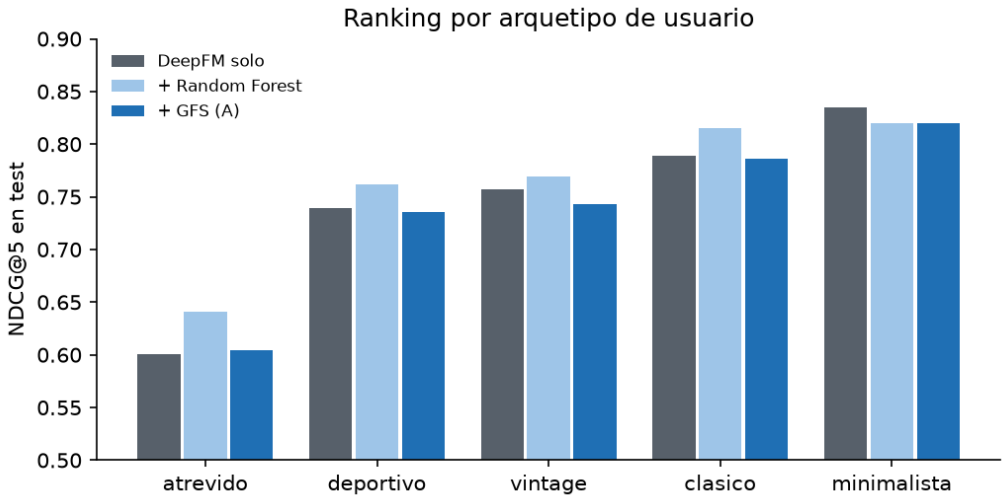


Figura 9. NDCG@5 en test por arquetipo de usuario.

III. Implementación e integración con la base de datos común

1. Arquitectura

La base de datos común del proyecto es un libro Excel, **BD_modelo_fly.xlsx** (15,6 MB, 11 hojas). Los modelos se entrenan en Google Colab con GPU, cuando necesitan PyTorch, y en local. Los pesos del DeepFM se exportan a un archivo de 115 KB y se ejecutan con numpy, así que la recomendación corre en cualquier computadora con el requirements.txt del repositorio. Se verificó que la versión en numpy da lo mismo que PyTorch: la diferencia máxima es $1{,}95 \cdot 10^{-7}$ en 35 000 candidatos.

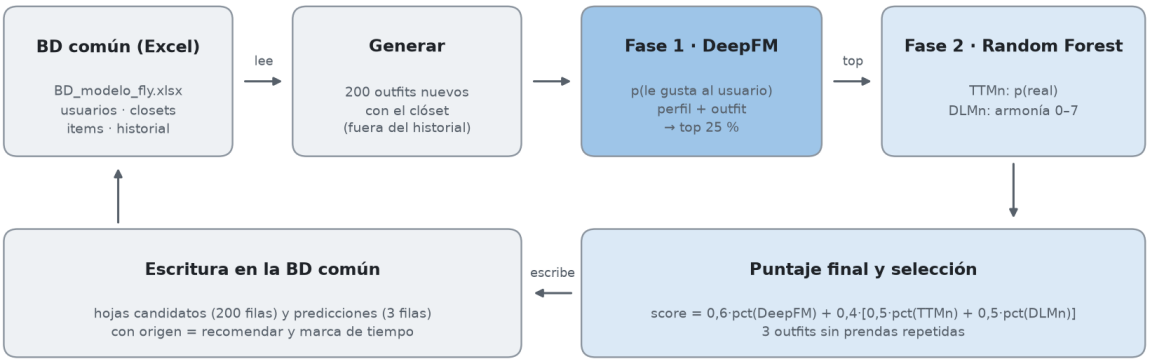


Figura 10. Flujo de recomendar(user_id): lee la BD común, pasa por las dos fases y escribe el resultado en la misma BD.

Tabla 13. Hojas de la base de datos común.

Hoja	Contenido	Filas	Escribe
items	Prendas con sus atributos (Polyvore + catálogo propio)	65 866	Preparación
outfits	Outfits reales y negativos con las 7 reglas	45 036	Preparación
usuarios	Datos de registro y parámetros ocultos de la simulación	350	Simulación
closets	Prendas de cada usuario	20 997	Simulación
historial	50 decisiones por usuario (35 / 7 / 8)	17 500	Simulación
candidatos	Outfits que se ordenan, con la probabilidad del DeepFM	52 500 + recomendar()	Modelos
predicciones	Ranking final: TTMn, DLMn, score y rango	7 000 + recomendar()	Modelos
metricas	Métricas de la fase 2 y del ranking por semilla	194	Modelos
impacto_ods	Indicadores del ODS 12	8	Integración
diccionario	Significado de cada columna	116	Integración

2. Evidencia de integración

La función recomendar(user_id) sigue cinco pasos:

1. Lee del Excel el perfil, el clóset y el historial del usuario.
2. Arma 200 outfits nuevos con su clóset, que no estén en su historial.
3. El DeepFM se queda con el 25 % y el Random Forest lo reordena.

4. Elige 3 outfits que no repiten prendas.
5. Agrega las filas a las hojas candidatos y predicciones, con origen = recomendar y marca de tiempo.

Se ejecutó para tres usuarios de perfiles distintos:

Tabla 14. Filas de la BD común antes y después de recomendar() para U001, U004 y U301.

Hoja	Antes	Después	Agregadas
candidatos	52 500	53 100	+600
predicciones	7 000	7 009	+9

Por ejemplo, para U301 (clóset 100 % del catálogo propio, estilo favorito casual, Lima) la primera recomendación es una camiseta gris de estilo años 90, un pantalón denim azul de los 90 y un calzado blanco. Tiene probabilidad DeepFM 0,93, TTMn 0,38, DLMn 7,0 y score final 0,986. Además, el Random Forest reentrenado al cargar los modelos repite las métricas de la fase 2 (AUC 0,624 frente a 0,623; MAE 0,190).

3. Dashboard

El dashboard preliminar del Hito 2 no se construyó; el dashboard de visualización (Streamlit) queda para el Hito 4. Leerá la misma BD común: recomendaciones por usuario, métricas por experimento e indicadores de impacto. También agregará una hoja de opinión (me gusta / no me gusta) para medir la aceptación con personas reales.

IV. Análisis de impacto ODS y ética de datos

1. Impacto en el ODS 12

El sistema solo combina prendas que el usuario ya tiene, así que cada recomendación aceptada es un outfit «nuevo» que no requiere comprar ropa. La Ellen MacArthur Foundation (2017) reporta que el número de veces que se usa una prenda antes de desecharla cayó 36 % en quince años; aumentar el uso de lo que ya existe es una de sus estrategias para reducir el impacto de la industria textil, que también es relevante para el ODS 13. El impacto se midió con recomendar() sobre los 350 usuarios (3 recomendaciones cada uno), usando el gusto simulado como juez:

Tabla 15. Indicadores de impacto ODS 12.

Indicador	Valor	Meta ODS
Recomendaciones armadas solo con prendas del clóset	100 %	12.5 (reutilizar)
Probabilidad de que el usuario acepte una recomendación	**80,3 %**	12.2
… si elige 3 outfits al azar de su clóset (sin recomendador)	52,4 %	Línea base
Mejora relativa frente al azar	**+53 %**	12.2
Aceptación en usuarios con clóset 100 % del catálogo propio	88,6 %	12.8
Prendas distintas puestas en uso por usuario (3 outfits)	12,6 de 60	12.5
Prendas recomendadas que el usuario nunca había usado en un outfit aceptado	13,1 %	12.5 (alargar la vida útil)

Con el DeepFM solo la aceptación esperada es 80,5 %: en impacto, la segunda fase no suma, igual que en el ranking. **Límite:** el juez es la simulación; con personas reales este indicador se medirá con la opinión del usuario (Hito 4).

2. Sesgos y ética

- **Sesgo de género:** Polyvore es casi todo ropa de mujer (3 441 ítems de categorías de hombre entre 142 480). Por eso el 85 % de los usuarios simulados son mujeres, y el sistema no debe presentarse como válido para ropa de hombre sin datos nuevos.
- **Usuarios simulados:** el gusto lo programamos nosotros con 5 arquetipos. El modelo no ve el arquetipo, pero los resultados describen qué tan bien se recupera un gusto conocido, no el de personas reales.
- **Datos generados por IA:** el catálogo propio tiene atributos casi aleatorios. Se declaró, se revisó a mano y no se usa como verdad.
- **Variables sensibles:** edad, género y ciudad entran al DeepFM, pero en la simulación no influyen en el gusto (salvo el clima de la ciudad). Así se puede comprobar que el modelo no saca conclusiones de ellas. No hay datos personales reales: los usuarios tienen ID anónimos (U001–U350).
- **Honestidad del resultado:** H1 no se sostiene y se informa así, con los controles que lo muestran. El 100 % de precisión de la primera validación de color se reporta solo como cota superior, y en su lugar se usa la revisión a ciegas (82,5 %).
- **Transparencia del origen de cada dato:** cada atributo guarda si salió del texto, de la categoría, de la foto o de un supuesto.

V. Confluencia con el ecosistema y lecciones aprendidas

1. Cómo consume el modelo los datos de la BD común

recomendar(user_id) lee las hojas usuarios, closets, items e historial; codifica el perfil (6 campos) y cada outfit (464 columnas), y escribe en candidatos y predicciones. Comprueba que el vocabulario de usuarios del libro coincide con el que se usó para entrenar el DeepFM; si no coincide, avisa que hay que reentrenar en lugar de dar predicciones equivocadas. El diccionario de datos (Anexo B) fija el significado de cada columna para quien lea o escriba el libro.

2. Lecciones aprendidas

- **La fuga se esconde en las particiones.** Una partición al azar habría dejado al 70 % de los outfits de test con productos vistos en train. Hubo que partir por grupos de outfits conectados por sus productos, y además evitar que un outfit de test de un usuario estuviera en el train de otro (la primera versión tenía 14 casos).
- **Las reglas no bastan como verdad.** Si la etiqueta sale de las mismas reglas que ve el modelo, cualquier árbol llega a ~100 % y la hipótesis no se puede contrastar. La compatibilidad aprendida de outfits reales resolvió esa circularidad.
- **Una arquitectura biológica trae sus restricciones.** El cuello de botella de 2 neuronas hizo que la red «muriera» con ReLU. Hubo que diagnosticarlo con la actividad de DNp01 antes de comparar con los controles.
- **Integrar entornos distintos.** Colab (GPU, PyTorch) y la computadora local se conectaron con archivos de resultados versionados. El DeepFM se exportó a numpy para no exigir PyTorch al recomendar.
- **Un Excel como base de datos tiene costo.** Abrir y guardar un libro de 15 MB tarda; por eso recomendar() permite acumular varias recomendaciones y escribirlas una sola vez.

VI. Conclusiones y siguientes pasos

1. Se construyó un recomendador de outfits en dos fases que ordena el clóset de cada usuario con NDCG@5 = 0,767, frente a 0,492 al azar y 0,919 como máximo. El usuario aceptaría el 80,3 % de las recomendaciones, frente al 52,4 % al azar.
2. La red con la conectividad del Giant Fiber System es tan buena como un MLP de su tamaño, pero no mejor que la misma red con las conexiones barajadas. **La conectividad específica de la mosca no aporta** en esta tarea: se acepta H0.
3. Para decidir si un outfit combina, los modelos tabulares (Random Forest, XGBoost) superan a las redes con la misma información, y son los que se integran.
4. El sistema se integró con la base de datos común: lee y escribe el Excel, con evidencia de filas antes y después.

Siguientes pasos (Hito 4): dashboard en Streamlit sobre la BD común, hoja de opinión para medir la aceptación con personas reales, video de demostración y manual de usuario.

Limitaciones

1. El gusto de los usuarios es simulado; lo real es qué combinan las personas en Polyvore.

2. Los atributos de Polyvore salen del texto y de la foto, no de etiquetas de expertos; el color se validó a ciegas en solo 40 prendas.
3. Las reglas P1 y P2 son aproximaciones, Ep1 no aplica a Polyvore y el 80,8 % de los outfits reales cumple las 7 reglas.
4. El conectoma no trae las sinapsis eléctricas; 12 de 327 neuronas toman el neurotransmisor de la literatura.
5. Para evitar la fuga, valid y test tienen más vestidos que train (37 % frente a 24 %).
6. El resultado sobre H1 vale para esta forma de conectar el outfit al conectoma (capa lineal a las 311 neuronas de entrada, 4 pasos de propagación).

Bibliografía

Ache, J. M., et al. (2019). Neural basis for looming size and velocity encoding in the *Drosophila* giant fiber escape pathway. *Current Biology*. https://doi.org/10.1016/j.cub.2019.01.079

Allen, M. J., Godenschwege, T. A., Tanouye, M. A. y Phelan, P. (2006). Making an escape: Development and function of the *Drosophila* giant fibre system. *Seminars in Cell & Developmental Biology, 17*(1), 31–41.

Berg, S., et al. (2026). Sexual dimorphism in the complete *Drosophila* male central nervous system connectome. *Cell*. https://doi.org/10.1016/j.cell.2026.08.015

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 785–794.

Dior, C. (1954). *The Little Dictionary of Fashion*. Cassell.

Ellen MacArthur Foundation (2017). *A New Textiles Economy: Redesigning fashion's future*.

Faerm, S. (2010). *Fashion Design Course*. Barron's.

Flusser, A. (2002). *Dressing the Man*. HarperCollins.

García, N. (2007). *The Little Black Book of Style*. Harper.

Guo, H., Tang, R., Ye, Y., Li, Z. y He, X. (2017). DeepFM: A factorization-machine based neural network for CTR prediction. *Proceedings of IJCAI*, 1725–1731.

Han, X., Wu, Z., Jiang, Y.-G. y Davis, L. S. (2017). Learning fashion compatibility with bidirectional LSTMs. *Proceedings of ACM Multimedia*, 1078–1086.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Itten, J. (1961). *The Art of Color*. Reinhold.

Järvelin, K. y Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems, 20*(4), 422–446.

Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems 30*.

Naciones Unidas (2015). *Transformar nuestro mundo: la Agenda 2030 para el Desarrollo Sostenible* (Objetivo 12). https://www.un.org/sustainabledevelopment/es/sustainable-consumption-production/

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Plaza, S. M., et al. (2022). neuPrint: An open access tool for EM connectomics. *Frontiers in Neuroinformatics, 16*, 896292.

Shiu, P. K., et al. (2024). A *Drosophila* computational brain model reveals sensorimotor processing. *Nature, 634*, 210–219.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin, 1*(6), 80–83.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212.

Anexos

A. Repositorio y reproducibilidad

Código, datos procesados y resultados: https://github.com/sowiexsker894/Predicci-n-de-compatibilidad-de-outfits-desde-el-conectoma-del-Giant-Fiber-System

El README explica la instalación. Cada notebook dice en su primera celda qué lee y qué escribe; desde el 05a se pueden correr de forma independiente.

Tabla 16. Notebooks del Hito 3.

Notebook	Dónde	Qué hace
00_polyvore_descarga	local	Descarga los metadatos de Polyvore
01c_color_imagenes_colab	Colab	Color dominante de las fotos
01_atributos	local	Atributos desde el nombre y la foto
01b_catalogo_propio	local	Catálogo propio al esquema común
02_validacion_muestra	local	Validación manual de 200 prendas
03_particion	local	Partición 70/15/15 sin productos compartidos
04_negativos_reglas	local	Negativos (TTMn) y las 7 reglas (DLMn)
05a_conectoma_descarga_colab	Colab	Descarga del conectoma desde neuPrint
05b_conectoma_red	local	Signo, máscara y estructura de la red
06_usuarios_simulados	local	350 usuarios con clóset e historial
07a_candidatos	local	Candidatos de valid y test
07b_fase2_colab	Colab (GPU)	Fase 2: árboles, red GFS y controles
07c_deepfm_colab	Colab (GPU)	Fase 1: DeepFM
07d_ranking_final	local	Seis experimentos, H1 y análisis de errores
08a_exportar_deepfm_colab	Colab	Exporta los pesos del DeepFM
08b_bd_comun	local	BD común, recomendar() e impacto ODS 12

B. Diccionario de datos

Columnas del libro BD_modelo_fly.xlsx. Las marcadas como OCULTO son parámetros de la simulación que el modelo no ve; sirven para evaluar.

Hoja	Columna	Tipo	Descripción
items	item_id	str	ID de la prenda: 'pv_' + ID de Polyvore, o 'P' + número del catálogo propio
items	origen	str	items: polyvore / propio · closets: de dónde viene la prenda · candidatos y predicciones: historial / nuevo (evaluación) o recomendar (escrito por recomendar())
items	particion	str	train / valid / test (en historial y candidatos es temporal por usuario; en outfits e items es por outfit de Polyvore)
items	name	str	Texto original de la prenda (nombre en Polyvore o descripción del catálogo propio)
items	slot	str	Lugar en el outfit: arriba, abajo, vestido, exterior, calzado, bolso, accesorio, joyeria
items	tono	str	Tono del color (claro, medio, oscuro…)
items	familia_color	str	Familia de color (neutro, cálido, frío…)

Hoja	Columna	Tipo	Descripción
items	patron	str	Patrón (liso, rayas, cuadros, floral…)
items	material	str	Material principal
items	estilo	str	Estilo (clasico, minimalista, vintage, atrevido, deportivo…)
items	calce	str	Calce (ajustado, regular, oversize)
items	epoca	str	Década o época que evoca
items	largo	str	Largo de la prenda (corto, medio, largo)
outfits	outfit_id	str	ID del outfit (Polyvore: set_id y sufijo del negativo; usuarios: U###_O## historial, U###_V/T### candidatos, U###_R<fecha>_### recomendar())
outfits	tipo	str	real (outfit armado por una persona en Polyvore) o el tipo de negativo (aleatorio, dificil)
outfits	real	int64	1 = outfit real de Polyvore, 0 = negativo. Etiqueta de TTMn (fase 2)
outfits	set_id_origen	int64	Outfit real del que sale el negativo (agrupa los folds de la validación cruzada)
outfits	particion	str	train / valid / test (en historial y candidatos es temporal por usuario; en outfits e items es por outfit de Polyvore)
outfits	n_items	int64	Cantidad de prendas del outfit
outfits	cambiadas	int64	Prendas cambiadas para armar el negativo
outfits	item_ids	texto	Prendas del outfit separadas por '|' (llaves de la hoja items)
outfits	aplica_C1	int64	1 si la regla C1 aplica al outfit
outfits	aplica_C2	int64	1 si la regla C2 aplica al outfit
outfits	aplica_P1	int64	1 si la regla P1 aplica al outfit
outfits	aplica_P2	int64	1 si la regla P2 aplica al outfit
outfits	aplica_P3	int64	1 si la regla P3 aplica al outfit
outfits	aplica_E1	int64	1 si la regla E1 aplica al outfit
outfits	aplica_Ep1	int64	1 si la regla Ep1 aplica al outfit
outfits	cumple_C1	int64	1 si el outfit cumple la regla C1
outfits	cumple_C2	int64	1 si el outfit cumple la regla C2
outfits	cumple_P1	int64	1 si el outfit cumple la regla P1
outfits	cumple_P2	int64	1 si el outfit cumple la regla P2
outfits	cumple_P3	int64	1 si el outfit cumple la regla P3
outfits	cumple_E1	int64	1 si el outfit cumple la regla E1
outfits	cumple_Ep1	int64	1 si el outfit cumple la regla Ep1
outfits	score_reglas	int64	Reglas de las 7 que cumple el outfit (0–7). Etiqueta de DLMn (fase 2)
usuarios	user_id	str	ID del usuario simulado (U001–U350)
usuarios	grupo	str	mixto (clóset 70 % Polyvore / 30 % propio) o transferencia (clóset 100 % catálogo propio)
usuarios	arquetipo	str	OCULTO al modelo. Gusto programado en la simulación (minimalista, clasico, vintage, atrevido, deportivo)
usuarios	estilo_fav	str	Estilo favorito declarado al registrarse
usuarios	edad	int64	Edad en años (el modelo la usa por tramos 18-24, 25-34, 35-45)
usuarios	genero	str	Género declarado
usuarios	ciudad	str	Ciudad del Perú
usuarios	clima	str	Clima de la ciudad (frio, templado, calido)
usuarios	n_closet	int64	Prendas en el clóset del usuario
usuarios	w_C1	float64	OCULTO. Peso de la regla C1 en el gusto simulado (cuánto le molesta romperla)
usuarios	w_C2	float64	OCULTO. Peso de la regla C2 en el gusto simulado (cuánto le molesta romperla)

Hoja	Columna	Tipo	Descripción
usuarios	w_P1	float64	OCULTO. Peso de la regla P1 en el gusto simulado (cuánto le molesta romperla)
usuarios	w_P2	float64	OCULTO. Peso de la regla P2 en el gusto simulado (cuánto le molesta romperla)
usuarios	w_P3	float64	OCULTO. Peso de la regla P3 en el gusto simulado (cuánto le molesta romperla)
usuarios	w_E1	float64	OCULTO. Peso de la regla E1 en el gusto simulado (cuánto le molesta romperla)
usuarios	w_Ep1	float64	OCULTO. Peso de la regla Ep1 en el gusto simulado (cuánto le molesta romperla)
usuarios	b_estilo	float64	OCULTO. Peso del estilo favorito en el gusto simulado
usuarios	d_neutros	float64	OCULTO. Peso de los colores neutros
usuarios	c_clima	float64	OCULTO. Peso de vestir acorde al clima
usuarios	e_compat	float64	OCULTO. Peso de la compatibilidad humana (aprendida de Polyvore)
usuarios	ruido	float64	OCULTO. Fracción de decisiones invertidas al azar (5–10 %)
usuarios	sesgo	float64	OCULTO. Mediana de la utilidad del usuario (centra su tasa de aceptación)
closets	user_id	str	ID del usuario simulado (U001–U350)
closets	item_id	str	ID de la prenda: 'pv_' + ID de Polyvore, o 'P' + número del catálogo propio
closets	origen	str	items: polyvore / propio · closets: de dónde viene la prenda · candidatos y predicciones: historial / nuevo (evaluación) o recomendar (escrito por recomendar())
closets	slot	str	Lugar en el outfit: arriba, abajo, vestido, exterior, calzado, bolso, accesorio, joyeria
historial	user_id	str	ID del usuario simulado (U001–U350)
historial	orden	int64	Posición de la interacción en el tiempo (0–49)
historial	fecha	str	Fecha de la interacción o de la escritura
historial	outfit_id	str	ID del outfit (Polyvore: set_id y sufijo del negativo; usuarios: U###_O## historial, U###_V/T### candidatos, U###_R<fecha>_### recomendar())
historial	item_ids	str	Prendas del outfit separadas por '|' (llaves de la hoja items)
historial	n_items	int64	Cantidad de prendas del outfit
historial	particion	str	train / valid / test (en historial y candidatos es temporal por usuario; en outfits e items es por outfit de Polyvore)
historial	viola_C1	int64	1 si el outfit rompe la regla C1
historial	viola_C2	int64	1 si el outfit rompe la regla C2
historial	viola_P1	int64	1 si el outfit rompe la regla P1
historial	viola_P2	int64	1 si el outfit rompe la regla P2
historial	viola_P3	int64	1 si el outfit rompe la regla P3
historial	viola_E1	int64	1 si el outfit rompe la regla E1
historial	viola_Ep1	int64	1 si el outfit rompe la regla Ep1
historial	score_reglas	int64	Reglas de las 7 que cumple el outfit (0–7). Etiqueta de DLMn (fase 2)
historial	p_real	float64	Probabilidad de aceptar según la simulación (verdad oculta; solo para evaluar y como techo)
historial	aceptado	int64	1 = el usuario aceptó el outfit, 0 = lo rechazó. Etiqueta del DeepFM y de las métricas de ranking
candidatos	user_id	str	ID del usuario simulado (U001–U350)
candidatos	outfit_id	str	ID del outfit (Polyvore: set_id y sufijo del negativo; usuarios: U###_O## historial, U###_V/T### candidatos, U###_R<fecha>_### recomendar())
candidatos	item_ids	str	Prendas del outfit separadas por '|' (llaves de la hoja items)

Hoja	Columna	Tipo	Descripción
candidatos	particion	str	train / valid / test (en historial y candidatos es temporal por usuario; en outfits e items es por outfit de Polyvore)
candidatos	origen	str	items: polyvore / propio · closets: de dónde viene la prenda · candidatos y predicciones: historial / nuevo (evaluación) o recomendar (escrito por recomendar())
candidatos	n_items	int64	Cantidad de prendas del outfit
candidatos	p_real	float64	Probabilidad de aceptar según la simulación (verdad oculta; solo para evaluar y como techo)
candidatos	aceptado	int64	1 = el usuario aceptó el outfit, 0 = lo rechazó. Etiqueta del DeepFM y de las métricas de ranking
candidatos	p_deepfm	float64	Fase 1: probabilidad de que el usuario lo acepte según el DeepFM
candidatos	en_top	int64	1 = el outfit pasó el filtro del DeepFM (top 25 % del usuario)
candidatos	fecha	str	Fecha de la interacción o de la escritura
predicciones	user_id	str	ID del usuario simulado (U001–U350)
predicciones	outfit_id	str	ID del outfit (Polyvore: set_id y sufijo del negativo; usuarios: U###_O## historial, U###_V/T### candidatos, U###_R<fecha>_### recomendar())
predicciones	item_ids	str	Prendas del outfit separadas por '|' (llaves de la hoja items)
predicciones	experimento	str	Sistema que generó la predicción (3 · DeepFM + Random Forest, el mejor del paso 7d)
predicciones	p_deepfm	float64	Fase 1: probabilidad de que el usuario lo acepte según el DeepFM
predicciones	p_ttmn	float64	Fase 2: probabilidad de que el outfit sea real/compatible (salida TTMn, Random Forest)
predicciones	dlmn	float64	Fase 2: armonía predicha 0–7 (salida DLMn, Random Forest)
predicciones	score_final	float64	α·pct(DeepFM) + (1 − α)·[β·pct(TTMn) + (1 − β)·pct(DLMn)], con α = 0,6 y β = 0,5 (elegidos en valid)
predicciones	rango	int64	Posición en el ranking final del usuario (1 = primera recomendación)
predicciones	aceptado	int64	1 = el usuario aceptó el outfit, 0 = lo rechazó. Etiqueta del DeepFM y de las métricas de ranking
predicciones	origen	str	items: polyvore / propio · closets: de dónde viene la prenda · candidatos y predicciones: historial / nuevo (evaluación) o recomendar (escrito por recomendar())
predicciones	fecha	str	Fecha de la interacción o de la escritura
metricas	fuente	str	Notebook o paso que produjo la métrica
metricas	experimento	str	Sistema que generó la predicción (3 · DeepFM + Random Forest, el mejor del paso 7d)
metricas	modelo	str	Modelo o sistema evaluado
metricas	semilla	int64	Semilla de entrenamiento
metricas	metrica	str	Nombre de la métrica
metricas	valor	float64	Valor de la métrica
impacto_ods	indicador	str	Indicador de impacto
impacto_ods	valor	str	Valor de la métrica
impacto_ods	meta_ods	str	Meta del ODS 12 a la que aporta
impacto_ods	como_se_mide	str	Cálculo
diccionario	hoja	texto	Hoja del libro
diccionario	columna	texto	Columna
diccionario	tipo_dato	texto	Tipo de dato
diccionario	descripcion	texto	Significado